


# ALGORITMEN & DATASTRUCTUREN COLLEGE 5

parsing: recognize input & build trees



## the goal

"12 \* 34 + 5 \* 6"



## the approach

- define a grammar for the input

$E \rightarrow E \circ E \mid ( E ) \mid \text{id} \mid \text{Number}$

$\circ \rightarrow + \mid - \mid * \mid /$

- a recursive parse function for each rule in the grammar

```
public class RDparser
```

```
{ public RDparser ( String s );
```

```
  public BasicNode parseExpr ( );
```

```
  public BasicNode parseld ( );
```

```
  public BasicNode parseNumber ( );
```

```
  ...
```

## parseerbomen

- bomen representeren ook goed complexe invoer
  - ▣ door boomstructuur is het eenvoudiger de input te analyseren en manipuleren

- voorbeelden

- ▣ compiler, IDE
- ▣ spreadsheets, rekenmachine
- ▣ bewijssystemen
- ▣ spellingscontrole
- ▣ alle systemen met een dedicated taaltje
- ▣ ..

- het maken van een boom die de invoer representeert heet **parseren**

- ▣ we bekijken hier de principes

## herkennen van invoer: parseren

5

- herken invoer volgens gegeven regels
- goede regels zijn het halve werk
- er zijn verschillende formalismen in gebruik om de invoer vast te leggen
  - ▣ reguliere expressies
  - ▣ contextvrije grammatica
  - ▣ ..

## zinnen en talen

6

- alfabet  $\Sigma$ :
  - ▣ verzameling van symbolen die mogen voorkomen
  - ▣ binair:  $\Sigma = \{ 0, 1 \}$
  - ▣ hexadecimaal:  
 $\Sigma = \{ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F \}$ 
    - ▣ ook te schrijven als [0-9A-F]
- zin: eindig rijtje symbolen
  - ▣  $\varepsilon$  is de lege zin ( heeft lengte 0 )
  - ▣ lengte van een zin is altijd eindig
- taal: verzameling van zinnen
  - ▣  $\emptyset$  lege taal, niet gelijk aan  $\{ \varepsilon \}$
  - ▣ mag wel oneindig groot zijn

## manipulatie van zinnen/talen

7

- concatenatie zinnen:  
maak zin door er 2 achter elkaar te plakken
  - ▣ als  $s = 12$  en  $t = 34$ , dan is  $s t$  gelijk aan 1234
  - ▣ als er geen verwarring is schrijven we  $s t$  als  $st$
  - ▣  $s \varepsilon = \varepsilon s = s$
- concatenatie talen:  
plak zinnen achter elkaar, uit iedere taal eentje
  - ▣  $LM = \{ st \mid s \in L \wedge t \in M \}$
  - ▣  $LM \neq ML$
- vereniging: gooi alle zinnen bij elkaar in 1 taal
  - ▣  $L \cup M = \{ s \mid s \in L \vee s \in M \}$
  - ▣  $L \cup M = M \cup L$

## manipulatie van zinnen/talen 2

8

- exponent zin  $s^i$ :  
plak zin  $i$  keer achter zichzelf
  - ▣  $s^0 = \varepsilon$
  - ▣ voor  $i > 0$ :  $s^i = s^{i-1}s$  (of  $s^i = s s^{i-1}$ )
  - ▣ als  $s = 10$  dan is  $s^3 = 101010$
- exponent taal
  - ▣  $L^0 = \{ \varepsilon \}$
  - ▣  $L^i = L^{i-1}L$
- afsluiting: zinnen uit  $L$  zo vaak achter elkaar als je wil
  - ▣  $L^* = L^0 \cup LL^*$
- positieve afsluiting: minstens één keer  $L^+ = LL^*$

## reguliere expressies

9

- $\epsilon$  beschrijft taal  $\{\epsilon\}$
- ieder  $a$  ( voor  $a \in \Sigma$  ) beschrijft  $\{a\}$
- als  $r$  de taal  $L$  beschrijft dan beschrijft  $(r)$  ook  $L$
- $(r)|(s)$  beschrijft  $L(r) \cup L(s)$
- $(r)(s)$  beschrijft  $L(r) L(s)$
- $(r)^*$  beschrijft  $(L(r))^*$ ;  $(r)^+$  beschrijft  $(L(r))^+$
- $r ?$  is afkorting voor:  $r \mid \epsilon$
- minder haakjes:
  - voor iedere operator  $o$ :  $r o s o t$  lezen als  $(r o s) o t$
  - $*$  en  $+$  binden het sterkst
  - dan concatenatie
  - dan keuze

## reguliere definities

10

- geef namen aan reguliere expressie
  - definitie voor gebruik
  - geen recursie, of alleen aan einde/begin eigen rechterkant
  - namen vet om verwarring met symbolen te voorkomen
- voorbeeld: identifiers in C++/Java
 

<b>letter</b>	$\rightarrow [a-z] \mid [A-Z]$
<b>cijfer</b>	$\rightarrow [0-9]$
<b>underscore</b>	$\rightarrow \_$
<b>identifier</b>	$\rightarrow ( \text{letter} \mid \text{underscore} )^*$ $\quad ( \text{letter} \mid \text{underscore} \mid \text{cijfer} )^*$
- beschrijft:  $[a-zA-Z\_][a-zA-Z\_0-9]^*$
- integer**  $\rightarrow [-+]? [0-9]^+$
- natural**  $\rightarrow \text{cijfer natural} ?$

geeft Kleene star

## kracht reguliere definities

11

- uitstekende geschikt voor definitie van taalelementen
  - identifiers, getallen, ..
- kan niet de taal beschrijven die alleen netjes geneste paren haakjes bevat
- de reguliere definitie
 

**haakjes**  $\rightarrow ( \text{*} )^*$

  - bevat ook ((( en ( )), ...

bold om aan te geven dat het symbolen zijn

voorkom verwarring door gewone haakjes te verbieden

## contextvrije grammatica's

12

- ziet er uit als reguliere definitie, maar
  - mag gebruikt worden voor definitie, en
  - mag recursief zijn
- lost probleem met geneste haakjes op:
 

haakjes  $\rightarrow ( \text{haakjes} ) \text{haakjes} \mid \epsilon$
- we houden vaak de reguliere definities voor zaken als namen en cijfers
  - hoewel die ook met een CFG gaan
  - reguliere definities zijn veel eenvoudiger te parsen dan een CFG

Context Free Grammar

## voorbeeld CFG: expressies

13

- expr  $\rightarrow$  expr op expr
- expr  $\rightarrow$  ( expr )
- expr  $\rightarrow$  id
- expr  $\rightarrow$  **getal**
- op  $\rightarrow$  +
- op  $\rightarrow$  -
- op  $\rightarrow$  \*
- op  $\rightarrow$  /
- of
- E  $\rightarrow$  E O E | ( E ) | id | **getal**
- O  $\rightarrow$  + | - | \* | /
- als we niets anders zeggen is de eerste regel de startregel
- layout (spaties etc.) definiëren we nooit, maar mag (bijna) overal

## afleiding

14

- hoe maken we met de grammatica een zin
  - zolang er non-terminals (namen van productieregels) in staan moet je daar een invulling voor geven
  - E  $\rightarrow$  E \* E | E + E | num
- kortste afleiding:
  - E  $\Rightarrow$  num
- iets langer
  - E  $\Rightarrow$  E + E
  - $\Rightarrow$  E + E \* E
  - $\Rightarrow$  num + E \* E
  - $\Rightarrow$  num + num \* E
  - $\Rightarrow$  num + num \* num
- we zeggen ook
  - E  $\Rightarrow$  \* num + num \* num


volgorde van regels toepassen maakt vaak niet veel uit

## parse tree


15

- grafische weergave van afleiding

E  $\rightarrow$  E \* E | E + E | num




ook vaak getekend als:



## ambiguiteit

16


- ambigue: meer dan een afleidingen voor een zin
- verschillende afleidingen hebben vaak ander interpretatie
- voor E  $\rightarrow$  E \* E | E + E | num
- en de zin **num + num \* num**
- mogelijke afleidingen:



## ambiguiteit 2

17

- volgens de regels van de wiskunde is maar een van deze interpretaties juist
  - Meneer van dalen wacht op antwoord
- regel dit door de grammatica aan te passen:  
 $E \rightarrow T [+ E]$   
 $T \rightarrow F [* T]$   
 $F \rightarrow \text{num}$
- $12 * 34 + 5 * 6$  heeft nu 1 afleiding:  $(12 * 34) + (5 * 6)$



## parseren

18

- parseren: gegeven een zin en een CFG
  - vind een afleiding voor deze zin  
maak een parse tree ( een boom! )
  - of beslis dat zin niet tot de taal behoort
- twee aanpakken mogelijk
  - top-down:
    - begin met de start regel van de CFG
    - pas producties toe die nodig zijn om zin te herkennen
  - bottom up:
    - pak terminals, zoek er regels bij tot de hele zin geparseerd is
    - meeste tools werken op die manier
    - we bekijken dat verder niet

## recursive descent parsers

19

- parsers volgens de regels van de CFG
  - een parse functie voor elke nonterminal in de CFG
- we gebruiken bijna altijd een aparte **scanner** voor het herkennen van **tokens**
  - tokens zijn beschreven door reguliere definities en dus eenvoudig te herkennen

## Left-recursion

20

*Top-down parsers cannot handle left-recursion in the grammar parsed*

- the parser uses the same rule recursively without consuming any input: **infinite recursion**
- Formally, a grammar is left-recursive if
$$\exists A \in V_n \text{ such that } A \Rightarrow^+ A\alpha \text{ for some string } \alpha$$
- a simple expression grammar can be left-recursive:  
 $\text{expr} \rightarrow \text{expr} + \text{expr}$

## Eliminating left-recursion

21

- To remove left-recursion, we can transform the grammar
- Consider the grammar fragment:
 
$$\begin{array}{l} \text{foo} \rightarrow \text{foo } \alpha \\ \quad \quad | \quad \beta \end{array}$$
- where  $\alpha$  and  $\beta$  do not start with foo
- We can rewrite this as:
 
$$\begin{array}{l} \text{foo} \rightarrow \beta \text{ bar} \\ \text{bar} \rightarrow \alpha \text{ bar} \\ \quad \quad | \quad \epsilon \end{array}$$
- where bar is a new non-terminal
- This new grammar fragment contains no left-recursion

## removing empty productions

22

- $$\begin{array}{l} S \rightarrow X X \mid Y \\ X \rightarrow a X b \mid \epsilon \\ Y \rightarrow a Y b \mid Z \\ Z \rightarrow b Z a \mid \epsilon \end{array}$$
- all variables are *nullable*, e.g.  $Y \Rightarrow^* \epsilon$
  - duplicate each production with an occurrence of a nullable symbol, remove the nullable symbol in the copy
 
$$\begin{array}{l} S \rightarrow X X \mid X \mid Y \\ X \rightarrow a X b \mid ab \\ Y \rightarrow a Y b \mid ab \mid Z \\ Z \rightarrow b Z a \mid ba \end{array}$$
  - this can increase the size of the grammar significantly

## eliminating cycles ( $A \Rightarrow^+ A$ )

23

- if there are no  $\epsilon$ -productions
- replace each  $A \rightarrow B$  where B is cyclic by
 
$$\begin{array}{l} A \rightarrow \alpha \text{ s.t. } \alpha \text{ is not cyclic and} \\ C \rightarrow \alpha \text{ s.t. } B \Rightarrow^* C \end{array}$$
- example:
 
$$\begin{array}{l} S \rightarrow X \mid Xb \mid SS \\ X \rightarrow S \mid a \end{array}$$
- we have  $S \Rightarrow^+ S$  and  $X \Rightarrow^+ X$ 

$$\begin{array}{l} S \rightarrow a \mid Xb \mid SS \\ X \rightarrow Xb \mid SS \mid a \end{array}$$

we know how to remove them

## eliminating immediate left recursion

24

- replace
 
$$A ::= A\alpha_1 \mid \dots \mid A\alpha_m \mid \beta_1 \mid \dots \mid \beta_n$$
- by
 
$$\begin{array}{l} A \rightarrow \beta_1 A' \mid \dots \mid \beta_n A' \\ A' \rightarrow \alpha_1 A' \mid \dots \mid \alpha_m A' \mid \epsilon \end{array}$$
- example
 
$$S \rightarrow SX \mid SXb \mid XS \mid a$$
- replace this by
 
$$\begin{array}{l} S \rightarrow XSS' \mid aS' \\ S' \rightarrow XS' \mid SbS' \mid \epsilon \end{array}$$

we know how to remove this

## Predictive parsing: no backtracking

25

- **Basic idea:**  
for any two productions  $A \rightarrow \alpha \mid \beta$ , we would like a distinct way of choosing the correct production to expand
- for some RHS  $\alpha \in G$ , define  $\text{FIRST}(\alpha)$  as the set of tokens that appear *first* in some string derived from  $\alpha$ 
  - ▣ that is, for some  $w \in \text{FIRST}(\alpha)$  iff  $\alpha \Rightarrow^* w \gamma$
- **Key property:**  
Whenever two productions  $A \rightarrow \alpha$  and  $A \rightarrow \beta$  both appear in the grammar, we would like
 
$$\text{FIRST}(\alpha) \cap \text{FIRST}(\beta) = \emptyset$$
- This would allow the parser to make a correct choice with a look ahead of only **one** symbol!

## Left factoring

26

*what if a grammar does not have this property?*

- sometimes, we can *transform* a grammar to become this property
- for each non-terminal  $A$  find the longest prefix  $\alpha$  common to two or more of its alternatives.  
if  $\alpha \neq \epsilon$  then replace all of the  $A$  productions
 
$$A \rightarrow \alpha\beta_1 \mid \alpha\beta_2 \mid \dots \mid \alpha\beta_n$$
 with  $A \rightarrow \alpha A'$ 

$$A' \rightarrow \beta_1 \mid \beta_2 \mid \dots \mid \beta_n$$
 where  $A'$  is a new non-terminal
  - ▣ repeat this until no two alternatives for a single non-terminal have a common prefix

## Example of left factoring

27

Consider a right-recursive version of the expression grammar:

- 1  $\text{goal} \rightarrow \text{expr}$
- 2  $\text{expr} \rightarrow \text{term} + \text{expr}$
- 3      $\mid \text{term} - \text{expr}$
- 4      $\mid \text{term}$
- 5  $\text{term} \rightarrow \text{factor} * \text{term}$
- 6      $\mid \text{factor} / \text{term}$
- 7      $\mid \text{factor}$
- 8  $\text{factor} \rightarrow \text{num}$
- 9      $\mid \text{id}$

- To choose between productions 5, 6, & 7, the parser must see past the **num** or **id** and look at the **+**, **-**, **\***, or **/**.  
 $\text{FIRST}(2) \cap \text{FIRST}(3) \cap \text{FIRST}(4) \neq \emptyset$
- This grammar *fails* the test.

## Example of left factoring

28

There are two non-terminals that must be left factored:

- 2  $\text{expr} \rightarrow \text{term} + \text{expr}$
- 3      $\mid \text{term} - \text{expr}$
- 4      $\mid \text{term}$
- 5  $\text{term} \rightarrow \text{factor} * \text{term}$
- 6      $\mid \text{factor} / \text{term}$
- 7      $\mid \text{factor}$

Applying the **left factoring** transformation gives us:

- 2  $\text{expr} \rightarrow \text{term} \text{expr}'$
- 3  $\text{expr}' \rightarrow + \text{expr}$
- 4      $\mid - \text{expr}$
- 5      $\mid \epsilon$
- 6  $\text{term} \rightarrow \text{factor} \text{term}'$
- 7  $\text{term}' \rightarrow * \text{term}$
- 8      $\mid / \text{term}$
- 9      $\mid \epsilon$

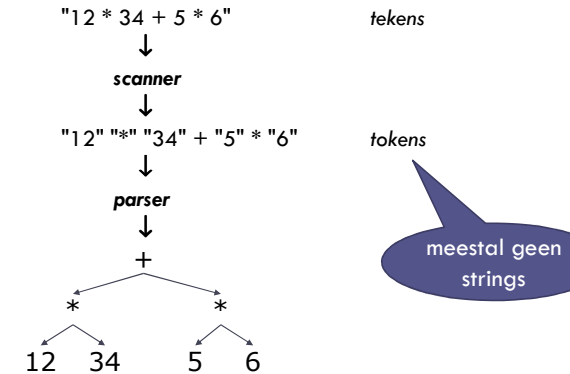
## opzet van programma

29

- splits invoer herkennen in 2 delen
  - ▣ scanner maakt van rij ascii-teken (String) een rij tokens
    - reguliere expressies als definitie van de tokens
  - ▣ parser maakt van deze tokens een parseerboom
    - contextvrije grammatica als definitie van zinnen
- we willen deterministische scanner en parser met lookahead 1
  - ▣ in de scanner we willen aan huidige teken kunnen zien welk token het moet worden
  - ▣ in de parser willen we aan het huidige token kunnen zien welke grammatica regel van toepassing is
  - ▣ dit voorkomt backtracking
    - er zijn ook parsers waar dit niet nodig is

## opzet van programma 2

30



## recursive descent parser in Java

31

- any parse error: throw a parse exception

```
public class ParseException extends Exception
{ /**
 * Creates a new instance of ParseException without detail message.
 */
    public ParseException ( ) { }
    /**
 * Constructs an instance of ParseException with the message.
 * @param msg the detail message.
 */
    public ParseException ( String msg )
    {
        super ( msg );
    }
}
```

## scanner

32

- we will demonstrate two ways to construct a scanner
  1. define a scanner class directly
    - ▣ simple and direct
    - ▣ somewhat more work
  2. build the scanner class upon the Java library to recognize regular expressions
    - ▣ the Java library does much of the hard work,
    - ▣ but we must know how to use it



## scanner

33

### □ used syntax

$E \rightarrow E \text{ op } E \mid \text{num}$

$\text{op} \rightarrow + \mid - \mid * \mid /$

$\text{num} \rightarrow -? [0-9]^+$

### □ we use an enumeration type for the tokens

`public enum Token`

```
{  
    Int, Plus, Minus, Times, Divide, Open, Close, EOF, Error;  
}
```

- ▣ the value of a number can be obtained separately by a method call from the scanner

## parseerboom


34

### □ we willen een boom bouwen die de structuur van de invoer weergeeft

- ▣ aparte knopen voor operatoren en getallen

### □ operatoren hebben getallen of expressies als argumenten

- ▣ maak één type knoop
- ▣ maak subtypes voor getallen etc.
- ▣ geef een operator pointers naar z'n argumenten



## knopen en subtypes

35

### □ één basis type Knoop voor alle knopen in de parse tree

- ▣ we kunnen ieder subtype als argument gebruiken

`abstract public class BasicNode`

```
{  
    abstract public String toString ( );  
    abstract public int value ( ) throws  
        Exception;  
}
```

### □ in Clean gebruiken we iets als

`:: Expr = Int Int | Operator Expr Op Expr`

## Integer Knoop

36

```
public class IntNode extends BasicNode  
{  
    private int i;  
    public IntNode ( int n )  
    {  
        i = n;  
    }  
    public String toString ( )  
    {  
        return Integer.toString ( i );  
    }  
    public int value ( )  
    {  
        return i;  
    }  
}
```

## operator knoop

37

```
public class OpNode extends BasicNode
{ public BasicNode l, r;
  public Token op;
  public OpNode ( ) { }
  public OpNode ( Token t )
  { op = t;
  }
  public OpNode ( BasicNode n1, Token t, BasicNode n2 )
  { l = n1;
    op = t;
    r = n2;
  }
  public String toString ( )
  {
    return ( "(" + l + " " + op + " " + r + ")" );
  }....
}
```

## operator knoop 2

38

```
public int value ( ) throws Exception
{ int x = l.value ( );
  int y = r.value ( );
  switch ( op )
  { case Plus: return x + y;
    case Minus: return x - y;
    case Times: return x * y;
    case Divide:
      if ( y != 0 )
        return x / y;
      else
        throw new Exception( "Opnode: try to devide by zero" );
    default:
      throw new Exception( "Opnode: Unknow operator: " + op );
  }
}
```

## scanning

39

- the current character tells which token is currently in the input
  - ▣ no backtracking necessary in the tokenizer
- there is one exception:
  - ▣ if you do not know the context you cannot tell whether the input -123 is
    1. a single token with value -123, or
    2. two tokens: a minus operator and an integer token
  - ▣ solution: always use the two token option and correct this in the parser if this is necessary

## using the Java scanner?

40

- the Java libraries provide a handy scanner class
- this works excellent if we know what to expect
- here it is less obvious what we can expect
  - ▣ e.g. is -123 a single token, or two tokens,
  - ▣ or do we expect a number of an expression
- hence we have to use something different

## input

41

- in our examples we use a String as input type
- in real parser we often use a file
- in Java we can handle both cases uniformly with a scanner
- here we use a special iterator class for characters in a string: StringCharacterIterator

## input by StringCharacterIterator

42

- we use a special iterator for characters in a string
- constructor:  
StringCharacterIterator( String text )
- methods used:  
char current ( )  
char next ( )
- checking for more input not by hasNext ( ), but  
input.current ( ) == CharacterIterator.DONE

## TokenizerDirect

43

```
public class TokenizerDirect
{
    StringCharacterIterator input;
    private Token tok;
    private int value = -1;
    /**
     * tokens are regular expressions with [0-9]+ | '+' | '-' | '*' | '/' | ')' | '('
     * @param s the string to parse
     * @throws ParseException
     */
    public TokenizerDirect ( String s ) throws ParseException
    {
        input = new StringCharacterIterator( s );
        scan ( );
    }
    public Token currentToken ( )
    {
        return tok;
    }
}
```

## TokenizerDirect 2

44

```
public int intValue ( ) throws ParseException
{
    if ( tok == Token.Int )
        return value;
    else
        throw new ParseException( "intValue: not available for " + tok );
}
public Token nextToken ( ) throws ParseException
{
    scan ( );
    return currentToken ( );
}
private int parseInt ( )
{
    int i = 0;
    for ( char c = input.current ( )
        ; c != CharacterIterator.DONE && Character.isDigit ( c )
        ; c = input.next ( )
    )
        i = 10 * i + Character.digit ( c, 10 );
    return i;
}
```

## TokenizerDirect 3

45

```
private void scan ( ) throws ParseException
{ if (input.current ( ) == CharacterIterator.DONE )
    tok = Token.EOF;
  else
  { char c = input.current ( );
    if ( Character.isWhitespace( c ) )
    { input.next ( );
      scan ( );
    } else
    { switch ( c )
      { case '+': tok = Token.Plus; break;
        case '-': tok = Token.Minus; break;
        case '*': tok = Token.Times; break;
        case '/': tok = Token.Divide; break;
        case '(': tok = Token.Open; break;
        case ')': tok = Token.Close; break;
        default:
          if ( Character.isDigit ( c ) )
          { tok = Token.Int;
            value = parseInt ( c );
          } else throw new ParseException ( "unknown token: " + c );
        }
      }
    }
  }
}
```

## using the Java library

46

- Java has a library to recognize regular expressions using this library we can easily create a tokenizer
- using this library we can specify regular expressions and obtain substrings matching this syntax in an iterator like fashion
- we will use only the basic features
- for a complete description see <http://download.oracle.com/javase/6/docs/api/java/util/regex/Pattern.html>

## character patterns

47

construct	matches
<b>x</b>	The character x
<b>\\</b>	The backslash character
<b>\\On</b>	The character with octal value On (0 <= n <= 7)
<b>\\Onn</b>	The character with octal value Onn (0 <= n <= 7)
<b>\\Omnn</b>	The character with octal value Omnn (0 <= m <= 3, 0 <= n <= 7)
<b>\\xhh</b>	The character with hexadecimal value 0xhh
<b>\\uhhhh</b>	The character with hexadecimal value 0xhhhh
<b>\\t</b>	The tab character ("\\u0009")
<b>\\n</b>	The newline (line feed) character ("\\u000A")
<b>\\r</b>	The carriage-return character ("\\u000D")
<b>\\f</b>	The form-feed character ("\\u000C")
<b>\\a</b>	The alert (bell) character ("\\u0007")
<b>\\e</b>	The escape character ("\\u001B")
<b>\\cx</b>	The control character corresponding to x

## Character classes in patterns

48

construct	matches
<b>[abc]</b>	a, b, or c (simple class)
<b>[^abc]</b>	Any character except a, b, or c (negation)
<b>[a-zA-Z]</b>	a through z or A through Z, inclusive (range)
<b>[a-d[m-p]]</b>	a through d, or m through p: [a-dm-p] (union)
<b>[a-z&amp;&amp;[def]]</b>	d, e, or f (intersection)
<b>[a-z&amp;&amp;[^bc]]</b>	a through z, except for b and c: [ad-z] (subtraction)
<b>[a-z&amp;&amp;[^m-p]]</b>	a through z, and not m through p: [a-lq-z](subtraction)

## Predefined character classes in patterns

49

construct	matches
.	Any character (may or may not match <a href="#">line terminators</a> )
\d	A digit: [0-9]
\D	A non-digit: [^0-9]
\s	A whitespace character: [ \t\n\x0B\f\r]
\S	A non-whitespace character: [^\s]
\w	A word character: [a-zA-Z_0-9]
\W	A non-word character: [^\w]

## quantifiers in patterns

50

construct	matches
X?	X, once or not at all
X*	X, zero or more times
X+	X, one or more times
X{n}	X, exactly n times
X{n,}	X, at least n times
X{n,m}	X, at least n but not more than m times

there are many more quantifiers  
giving fine control over matching

## our regular expression

51

- we have  
[0-9]+ | '+' | '-' | '\*' | '/' | ')' | '('
- as pattern in Java this is  
\\d+ | \\+ | \\- | \\\* | \\V | \\) | \\(  
  - since many of our special characters are special characters we need an \\ to escape them
  - since \\ is special in Java String we need to escape the escape character:  
"\\\\d+|\\\\+|\\\\-|\\\\\*|\\\\V|\\\\\\\\)\\\\\\\\(|"
  - we add a match any token to produce error messages

## the tokenizer

52

```
public class Tokenizer
{
    private Pattern pattern;
    private Matcher matcher;
    private Token tok;
    private int value = -1;
    /**
     * Constructor. Tokens are regular expressions with
     * [0-9]+ | '+' | '-' | '*' | '/' | ')' | '('
     * @param s the string to parse
     * @throws parsers.ParseException
     */
    public Tokenizer (String s) throws ParseException
    {
        pattern
            = Pattern.compile( "\\d+|\\\\+|\\\\-|\\\\*|\\\\V|\\\\\\\\)\\\\\\\\(|" );
        matcher = pattern.matcher( s );
        scan ( );
    }
}
```

## the tokenizer 2 (nothing different)

53

```
public Token currentToken ( )
{ return tok;
}
public int intValue ( ) throws ParseException
{ if ( tok == Token.Int )
    return value;
  else
    throw new ParseException
      ("intValue: not available for " + tok);
}
public Token nextToken ( ) throws ParseException
{ scan ( );
  return currentToken ( );
}
```

## the tokenizer 3: transform strings to tokens

54

```
private void scan ( ) throws ParseException
{ if (matcher.find ( ))
  { String token = matcher.group ( );
    if ( token.equals("+") ) tok = Token.Plus;
    else if ( token.equals("-") ) tok = Token.Minus;
    else if ( token.equals("*") ) tok = Token.Times;
    else if ( token.equals("/") ) tok = Token.Divide;
    else if ( token.equals("(") ) tok = Token.Open;
    else if ( token.equals(")") ) tok = Token.Close;
    else if ( Character.isDigit( token.charAt( 0 )))
    { tok = Token.Int;
      value = Integer.parseInt(token);
    } else throw new
      ParseException("unknown token: " + token);
  } else tok = Token.EOF;
}
```

ugly layout to put  
it all on one slide

## the tokenizer 3 better layout

55

```
private void scan ( ) throws ParseException
{ if (matcher.find ( ))
  { String token = matcher.group ( );
    if (token.equals( "+" ))
      tok = Token.Plus;
    else if (token.equals( "-" ))
      tok = Token.Minus;
    else if (token.equals( "*" ))
      tok = Token.Times;
    else if (token.equals( "/" ))
      tok = Token.Divide;
    else if (token.equals( "(" ))
      tok = Token.Open;
    else if (token.equals( ")" ))
      tok = Token.Close;
    else if ( Character.isDigit( token.charAt( 0 )))
    { tok = Token.Int;
      value = Integer.parseInt( token );
    } else throw new ParseException( "unknown token: " + token );
  } else tok = Token.EOF;
}
```

## recursive descent parser

56

```
public class RDparser
{ private Tokenizer tok;
  public RDparser ( String s ) throws ParseException
  { tok = new Tokenizer( s );
  }
  /**
   * starts parsing: E EOF
   * @return the parse tree if the whole input can be consumed
   * @throws parsers.ParseException
   */
  public BasicNode parse ( ) throws ParseException
  { BasicNode n = parseExpr ( );
    if ( tok.currentToken ( ) == Token.EOF )
      return n;
    else
      throw new ParseException( "end of input expected" );
  } ..
}
```

works also with  
other tokenizer

## parsing expressions

57

```
/**
 * Expr = Term (('+'|'-') Expr)?
 * @return parse tree
 * @throws parsers.ParseException
 */
public BasicNode parseExpr ( ) throws ParseException
{ BasicNode l = parseTerm ( );
  Token token = tok.currentToken ( );
  switch ( token )
  { case Plus:
    case Minus:
      tok.nextToken ( );
      BasicNode r = parseExpr ( );
      return new OpNode( l, token, r );
    default: return l;
  }
}
```

consume operator

## parsing terms

58

```
/**
 * Term = Factor (('*'|'/') Term)?
 * @return parse tree
 * @throws parsers.ParseException
 */
public BasicNode parseTerm ( ) throws ParseException
{ BasicNode l = parseFactor ( );
  Token token = tok.currentToken ( );
  switch ( token )
  { case Times:
    case Divide:
      tok.nextToken ( );
      BasicNode r = parseTerm ( );
      return new OpNode( l, token, r );
    default: return l;
  }
}
```

## parsing factor

59

```
/** Factor = ['-' ] Nat | '(' Exp ') '
 * @return parse tree
 * @throws parsers.ParseException
 */
public BasicNode parseFactor ( ) throws ParseException
{ switch ( tok.currentToken ( ) )
  { case Int:
    IntNode node = new IntNode( tok.intValue ( ) );
    tok.nextToken ( );
    return node;
    case Minus:
    if ( tok.nextToken ( ) == Token.Int )
    { IntNode node = new IntNode( tok.intValue ( ) * -1 );
      tok.nextToken ( );
      return node;
    }
    else throw new ParseException ( "number expected instead of " +
      tok.currentToken ( ) );
    case Open: ...
  }
```

## parsing factor 2

60

```
case Open:
  tok.nextToken ( );
  BasicNode tree = parseExpr ( );
  if ( tok.currentToken ( ) == Token.Close )
  {
    tok.nextToken ( );
    return tree;
  }
  else
    throw new ParseException ( " ) expected" );
default:
  throw new ParseException( "factor expected" );
}
```

## using these parsers

61

```
public class Main
{ public static void main(String[] args) { new Main ( ) }
  public Main ( )
  { Scanner in = new Scanner (System.in);
    while ( true )
    { try
      { System.out.print( "Enter input string to parse: " );
        String regel = in.nextLine ( );
        if ( regel.length ( ) == 0 ) break;
        TRparser parser = new TRparser( regel );
        BasicNode node = parser.parseExpr ( );
        System.out.print( "parse result: " + node );
        System.out.println( " with value " + node.value ( ) );
      } catch ( ParseException pe )
      { System.out.println( "Parse error: " + pe.getMessage ( ) );
      } catch ( Exception e )
      { System.out.println( "Error: " + e.getMessage ( ) );
      }
    }
  }
}
```

## building parse trees: associativity


62

- for operators like + and \* we can put the parenthesis in any way we want
  - e.g.  $1 + 2 + 3 = (1 + 2) + 3 = 1 + (2 + 3)$
- for other operators this does not hold e.g.
  - $(3 - 2) - 1 = 1 - 1 = 0$
  - $3 - (2 - 1) = 3 - 1 = 2$
  - $(3 - 2) - 1 \neq 3 - (2 - 1)$
  - default way of parsing:  $3 - 2 - 1 = (3 - 2) - 1$
  - similar  $8 / 2 / 2$  should have value 2 (instead of 8)

## associativity: parse trees

63

- parse trees for  $3 - 2 - 1$ :
- $3 - 2 - 1 = (3 - 2) - 1 = 0$



## associativity

64

- by changing
  - $E \rightarrow E - T \mid T$
  - to (in order to eliminate left recursion)
  - $E \rightarrow T - E \mid T$
  - we also introduce right associativity for a RD-parser
- simply applying rotates does not solve the problem
- solution: use
  - $E \rightarrow T (- T)^*$
  - as soon as we recognized  $E \rightarrow T_1 - T_2 (- T)^*$  we replace this by  $E \rightarrow T_3 (- T)^*$  where  $T_3 = T_1 - T_2$

a tail recursive parser



## tail recursive parser

65

```
/**
 * Expr = Term (('+'|'-') Term)*
 * @return parse tree
 * @throws parsers.ParseException
 */
public BasicNode parseExpr ( ) throws ParseException
{ BasicNode t = parseTerm ( );
  Token token = tok.currentToken ( );
  while
    (isElement( new Token [] {Token.Plus, Token.Minus}, token))
  { tok.nextToken ( );
    BasicNode r = parseTerm ( );
    t = new OpNode( t, token, r );
    token = tok.currentToken ( );
  }
  return t;
}
```

similar for other  
grammar rules

## haakjes

66

- zijn zeker van belang, maar geen knoop in de boom

$E \rightarrow T (+ T)^*$

$T \rightarrow F (* F)^*$



$F \rightarrow \text{num} \mid ( E )$

- voorbeeldjes

□  $1 * 2 + 3$

en

$1 * (2 + 3)$



## conclusie recursive descent parser

67

- het geheim is het maken van een geschikte grammatica
  - indien we verder dan 1 teken vooruit moeten kijken hebben we soms backtracking nodig
    - met de juiste syntax en grammatica hoeft dat niet
  - einde van de zin staat meestal niet in grammatica, moet je dus iets extra's voor verzinnen
- aanpak: splits in deelproblemen
  - invoer, scanner, één parser per syntax regel
- hier globale objecten voor invoer en scanner
  - kun je natuurlijk ook doorgeven, is wat onhandig
  - de parsers gebruiken alleen de scanner

## wat hebben we gedaan

68

- grammatica's
  - maak grammatica zodat je handig kunt parsen
    - geen linksrecursie
    - prioriteit van operatoren in grammatica
    - look ahead 1 d.m.v. left factoring
- parsen
  - recursive descent
    - handig als je met de hand een simpele parser maakt
    - volg de regeltjes van de grammatica direct
  - bindingsrichting operatoren
    - simpele verplaatsing van de recursie naar rechts maakt operatoren rechts associatief
    - een tail recursive parser lost dit probleem netjes op